資料探勘hw3

張丞君114961053

1. Use **k-nearest neighbors** with **k = 3**, **logistic regression**, **support vector machine**, and **random forest** to classify the instances in data set '**Diabetes**'.

(a) (10 points) Summarized the experimental results for k-fold cross validation with k = 5, 6, 7, 8, 9, 10.

	k=5	k=6	k=7	k=8	k=9	k=10
KNN (k=3)	73.3073	73.3073	74.3490	74.4792	74.2188	**72.6563**
Logistic	**77.8646**	76.5625	76.6927	77.7344	77.0833	77.4740
SVM	77.2135	76.9531	76.9531	77.3438	77.4740	77.3438
Random Forest	76.4323	76.3021	74.8698	76.6927	75.2604	75.7813

(b) (10 points) Discuss the impact of the number of folds on classification accuracy.

根據以上數據 ，可以觀察到folds對結果有以下影響：

1. **模型穩定度**：**Logistic** 與 **SVM** 在不同折數下的正確率波動較小，代表這類線性模型較穩定；而 **KNN** 波動較大，顯示局部模型更容易受到Fold 增減的影響；**Random Forest** 作為集成模型具有抗噪性，但當 k=9 正確率下降時，通常與隨機森林內部的隨機採樣機制與 Folds 切分的重疊有關。

2. **折數與資料量變化**：當折數增加（從 k=5 到 k=10），每次訓練所使用的資料量佔比會從 **80% 提升到 90%**。而訓練資料越多，模型越能抓到數據特徵，偏差（Bias）會越低，但也可能因為小範圍資料而導致結果產生細微不同。

3. **數據沒有隨著折數增加而上升**：觀察表格可以發現，正確率並沒有隨著 k 值增加而穩定上升，這是因為資料分佈不均，資料集中可能存在離群值，在特定的Fold 切分下，若某些極端值可能剛好被分到測試集，就會導致該折的正確率突然下降。另外，Diabetes 資料集約有 768 筆資料。當 k=10 時，測試集僅約 76 筆，測試樣本越少，單一筆預測錯誤對百分比的影響就越大，造成數值的變動。

(c) (30 points) When **k = 5 or 10** and significance level **alpha = 0.05**, perform statistical comparisons on each pair of the four algorithms to draw your conclusions.

1. 當 k = 5 ：

	樣本數768	Accuracy	Z值	P-value	結論
kNN (k=3)	563	0.7331	-2.0789	0.0376	P-value < 0.05, reject H0
Logistic	598	0.7786			兩分類正確率有顯著差別
		0.7559			
	樣本數768	Accuracy	Z值	P-value	結論
kNN (k=3)	563	0.7331	-1.774	0.0761	P-value > 0.05, do not reject H0
SVM	593	0.7721			兩分類正確率無顯著差異
		0.7526			
	樣本數768	Accuracy	Z值	P-value	結論
kNN (k=3)	563	0.7331	-1.4118	0.158	P-value > 0.05, do not reject H0
RandomForest	587	0.7643			兩分類正確率無顯著差異
		0.7487			
	樣本數768	Accuracy	Z值	P-value	結論
Logistic	598	0.7786	0.3057	0.7598	P-value > 0.05, do not reject H0
SVM	593	0.7721			兩分類正確率無顯著差異
		0.7754			
	樣本數768	Accuracy	Z值	P-value	結論
Logistic	598	0.7786	0.6685	0.5038	P-value > 0.05, do not reject H0
RandomForest	587	0.7643			兩分類正確率無顯著差異
		0.7715			
	樣本數768	Accuracy	Z值	P-value	結論
SVM	593	0.7721	0.3628	0.7168	P-value > 0.05, do not reject H0
RandomForest	587	0.7643			兩分類正確率無顯著差異
		0.7682			

2. 當 k = 10 ：

k=10	樣本數768	Accuracy	Z值	P-value	結論
kNN (k=3)	558	0.7266	-2.1821	0.0291	P-value < 0.05, reject H0 兩分類正確率有顯著差別
Logistic	595	0.7747			
		0.7507			
	樣本數768	Accuracy	Z值	P-value	結論
kNN (k=3)	558	0.7266	-2.1213	0.0339	P-value < 0.05, reject H0 兩分類正確率有顯著差異
SVM	594	0.7734			
		0.75			
	樣本數768	Accuracy	Z值	P-value	結論
kNN (k=3)	558	0.7266	-1.6986	0.0894	P-value > 0.05, do not reject H0 兩分類正確率無顯著差異
RandomFore	587	0.7578			
		0.7422			
	樣本數768	Accuracy	Z值	P-value	結論
Logistic	595	0.7747	0.061	0.9514	P-value > 0.05, do not reject H0 兩分類正確率無顯著差異
SVM	594	0.7734			
		0.7741			
	樣本數768	Accuracy	Z值	P-value	結論
Logistic	595	0.7747	0.4847	0.6279	P-value > 0.05, do not reject H0 兩分類正確率無顯著差異
RandomFore	587	0.7578			
		0.7663			
	樣本數768	Accuracy	Z值	P-value	結論
SVM	594	0.7734	0.4237	0.6718	P-value > 0.05, do not reject H0 兩分類正確率無顯著差異
RandomFore	587	0.7578			
		0.7656			

最終結論：

由以上表格可看出 **Logistic** 和 **kNN** 在 k=5 (P=0.0376) 或 k=10 (P=0.0291)時，**Logistic** 的正確率均顯著優於 **kNN**，這說明在 Diabetes 資料集，線性回歸模型比基於鄰近值的模型更具可靠性。另外在 k=5 時，kNN 與 SVM 沒有顯著差異；但當折數增加到 **k=10** 時，**SVM** 與 **kNN** 出現了顯著差異 (P=0.0339)，這暗示隨著訓練資料比例增加，SVM 的模型發揮得更好，也驗證了增加交叉驗證的折數可以提供更穩定的評估，有助於辨識出在小折數時被掩蓋的性能差異。